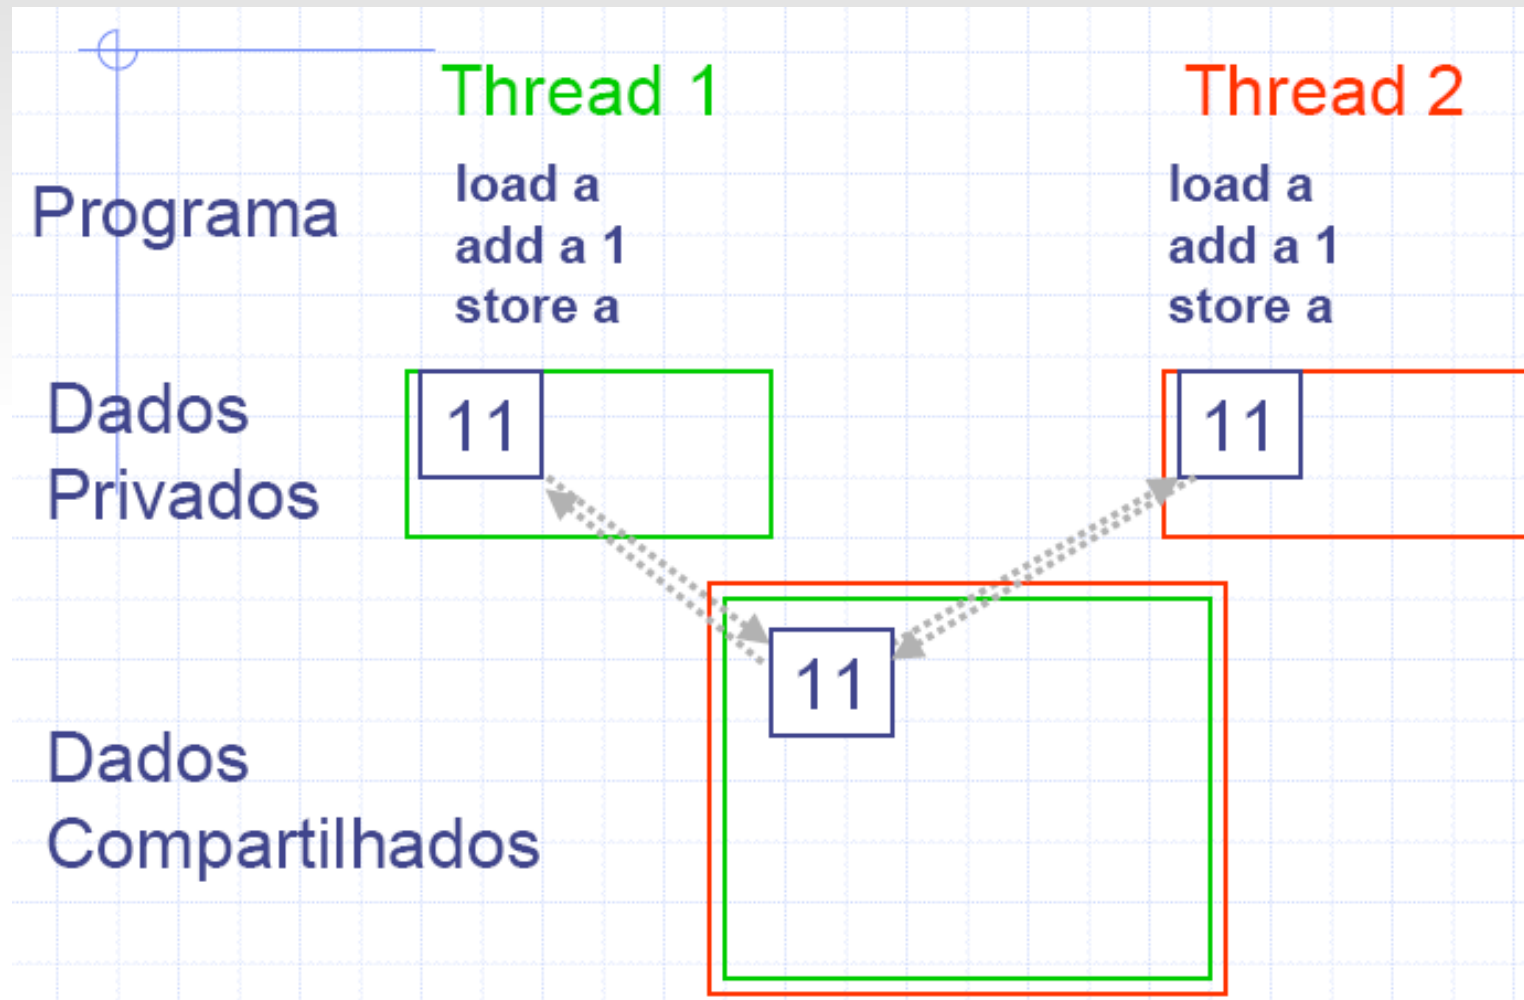


# OpenMP avançado

# Sincronização

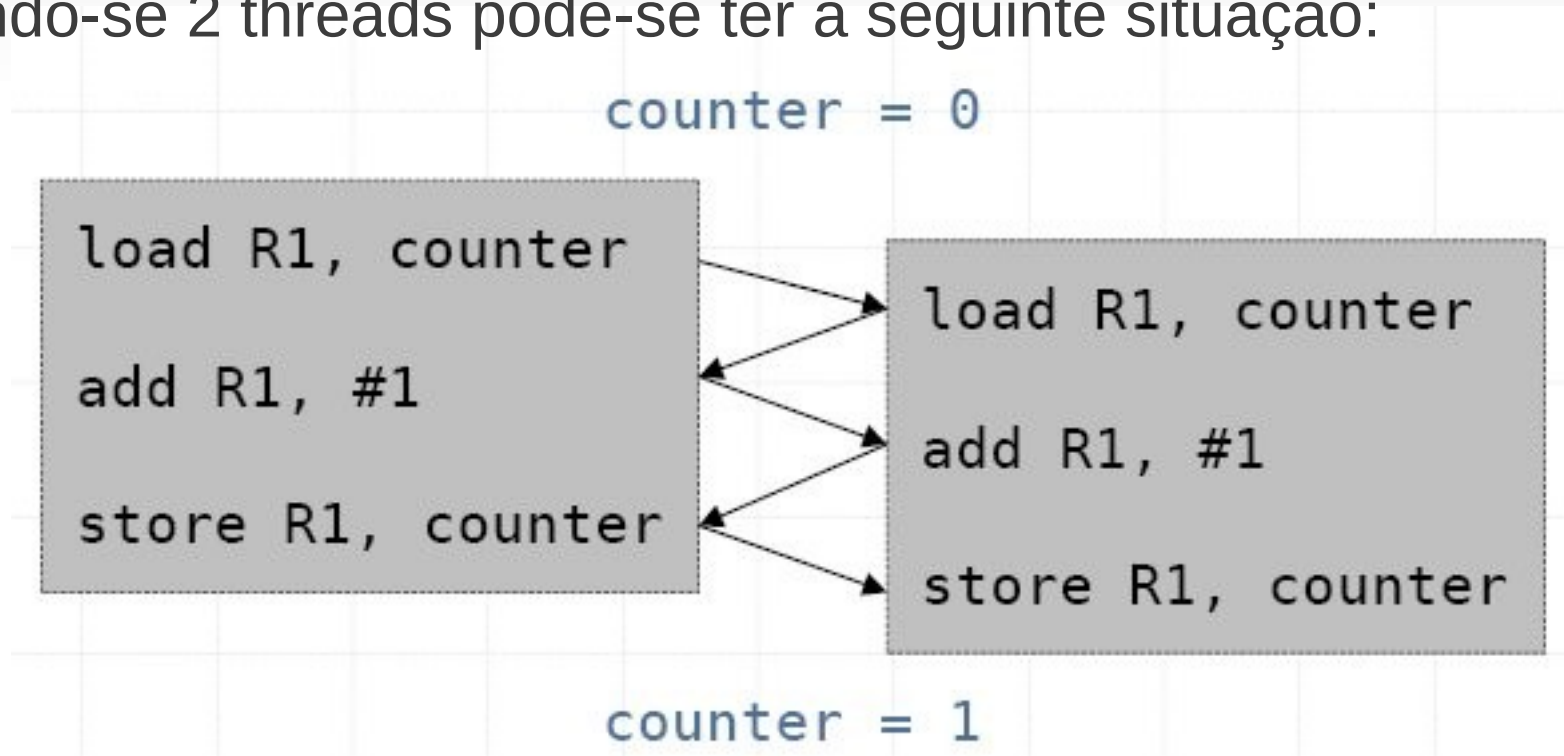
- Pode ser necessário assegurar que as ações em variáveis compartilhadas ocorram da maneira correta
  - Exemplos práticos:
    - a *thread* 1 deve escrever na variável *A* antes da *thread* 2 faça a sua leitura
    - a *thread* 1 deve ler a variável *A* antes que a *thread* 2 faça sua escrita.
  - Note que as atualizações para variáveis compartilhadas (p.ex.  $a = a + 1$ ) não são atômicas!
    - Se duas *threads* tentarem fazer isto ao mesmo tempo, uma das atualizações pode ser perdida.

# Exemplo de Sincronização



# Problemas em operações não atômicas

- Supondo uma dada variável compartilhada `counter` e uma operação do tipo:  
`counter++`
- Supondo-se 2 threads pode-se ter a seguinte situação:



# Solução do problema

- Resolver cada ação envolvendo uma variável compartilhada (como, por exemplo, counter++) **atomicamente**
  - Isto é, sem ser interrompida para intercalação e/ou sem sofrer ação de outro processo em paralelo
- Criação de uma **Seção Crítica**
  - Parte do programa que deve ser executada atomicamente
  - Normalmente implementada como um procedimento conhecido por **Exclusão Mútua (Mutual Exclusion)**: garante que apenas uma thread faz uma dada operação por vez.
    - Recursos da linguagem de prog.: Semáforos, monitores,


# Condição de corrida (*Data racing*)

- Duas ou mais diferentes threads tentam acessar a mesma área comum de memória:
  - De forma assíncrona
  - Sem a implementação de nenhuma trava ou barreira
  - Implementam operações do tipo *Load/Store*
- Significa que uma atualização em uma área de memória comum não está bem protegida

# Exemplos de condições de corrida


```
#pragma omp parallel shared(n)
```

```
{n = omp_get_thread_num();}
```



```
#pragma omp parallel shared(x)
```

```
{x = x + 1;}
```




# Sincronização explícita

- Pode ser necessário sincronizar ações em variáveis compartilhadas. Exemplos:
  - Assegurar a ordenação correta de leituras e escritas
  - Proteger a atualização de variáveis compartilhadas (não atômicas por padrão)
- Importante lembrar que existe uma barreira implícita no final das diretivas *DO/FOR*, *SECTIONS* e *SINGLE*



# Seções Críticas em OpenMP

- Bloco de código que só pode ser executado por uma *thread* por vez
  - Pode ser utilizado para proteger a atualização de variáveis compartilhadas e evitar a condição de corrida
  - A diretiva *CRITICAL* permite que as seções críticas recebam nomes
    - Se uma *thread* está em uma seção crítica com um dado nome, nenhuma outra *thread* pode estar em uma seção crítica com o mesmo nome (embora elas possam estar em seções críticas com outros nomes)
    - Se o nome é omitido, um nome nulo é assumido



# Exemplo básico para seção crítica em OpenMP

```
#include <omp.h>

main()
{
    int x;
    x = 0;
    #pragma omp parallel shared(x)
    {
        #pragma omp critical
        x = x + 1;
    } /* end of parallel section */
}
```

# Seção Crítica - Exemplo 2

- Colocando e retirando dado de uma pilha

```
#pragma omp parallel shared(stack), private(inext,inew)
...
#pragma omp critical (stackprot)
{
    inext = getnext(stack);
}
work(inext,inew);
#pragma omp critical (stackprot)
if (inew > 0) putnew(inew,stack);
}
...
```

# Diretiva *ATOMIC*

- Usada para proteger uma atualização única para uma variável compartilhada
- Aplica-se apenas a uma única sentença (forma "light" de se definir uma seção crítica)
- Sintaxe em C/C++:  
**#pragma omp atomic**  
**statement**
  - Onde *statement* deve ter uma das seguintes formas:
  - $x \text{ binop } = \text{expr}$ ,  $x++$ ,  $++x$ ,  $x--$ , or  $--x$ 
    - and binop is one of  $+$ ,  $*$ ,  $-$ ,  $/$ ,  $\&$ ,  $^$ ,  $<<$ , or  $>>$

# Diretiva ATOMIC - Exemplo


- Computar o grau de cada vértice em um grafo:

```
#pragma omp parallel for
for (j=0; j<nedges; j++) {
#pragma omp atomic
    degree[edge[j].vertex1]++;
#pragma omp atomic
    degree[edge[j].vertex2]++; }
```

# Sincronização por Barreira

## Diretiva *BARRIER*

- Nenhuma *thread* pode prosseguir além de uma barreira até que todas as outras *threads* cheguem até ela
  - Se alguma *thread* não encontrar a barreira: *DEAD LOCK!!!*
  - Usar com moderação pois pode causar atrasos na computação!



# Código Exemplo:

```
#pragma omp parallel private(i,myid,neighb)
{
myid = omp_get_thread_num();
neighb = myid - 1;

if (myid == 0) neighb = omp_get_num_threads() -
    1;
...

a[myid] = a[myid]*3.5;

#pragma omp barrier
b[myid] = a[neighb] + c
...
}
```

# Situação a se usar barreira

```
for (i=0; i < N; i++)  
    a[i] = b[i] + c[i];
```

*wait !*

*barrier*

```
for (i=0; i < N; i++)  
    d[i] = a[i] + b[i];
```



# A cláusula *NOWAIT*

- De forma a minimizar os tempos gastos com sincronização em OpenMP as diretivas/pragmas permitem o uso de uma cláusula opcional: *nowait*
  - Se esta cláusula estiver presente as threads não sincronizam (como por padrão) ao final de uma construção paralela como, por exemplo, "for"

```
#pragma omp for nowait  
{  
    :  
}
```

```
!$omp do  
    :  
    :  
!$omp end do nowait
```

29

# A more elaborate example

```
#pragma omp parallel if (n>limit) default(none) \
    shared(n,a,b,c,x,y,z) private(f,i,scale)
{
```

```
    f = 1.0;
```

```
#pragma omp for nowait
```

```
    for (i=0; i<n; i++)
        z[i] = x[i] + y[i];
```

```
#pragma omp for nowait
```

```
    for (i=0; i<n; i++)
        a[i] = b[i] + c[i];
```

```
    ....
```

```
#pragma omp barrier
```

```
    scale = sum(a,0,n) + sum(z,0,n) + f;
```

```
    ....
```

```
} /*-- End of parallel region --*/
```

Statement is executed  
by all threads

**parallel loop**  
(work is distributed)

**parallel loop**  
(work is distributed)

**synchronization**

Statement is executed  
by all threads

**parallel region**

# Cláusula IF

- Somente ativa uma seção paralela se o valor de uma dada expressão lógica for verdadeira
  - Se for falsa executa serial

```
#pragma omp parallel if (n > some_threshold) \  
    shared(n,x,y) private(i)  
{  
    #pragma omp for  
    for (i=0; i<n; i++)  
        x[i] += y[i];  
} /* -- End of parallel region -- */
```

# Balanceamento de carga em laços paralelo

- Em algumas operações sobre laços podem existir desbalanceamento de carga entre os processadores
  - Reduz ganhos de desempenho pois os processos mais rápidos deverão esperar (ociosos) pelo mais lento no ponto de sincronização
  - Exemplo:
    - Laço que chama uma função com argumento dado pelo índice que controla o laço
      - A função pode gastar mais ou menos CPU a cada iteração



```
#pragma omp parallel for  
for (int i=0; i<N; i++) {  
    a[i] = checar_se_e_primo(i); }
```

# Escalonamento

## Cláusula *SCHEDULE*

- A cláusula *SCHEDULE* permite uma variedade de opções por especificar quais iterações dos laços são executadas por quais *threads*.
  - Sintaxe em C/C++:
    - `schedule (kind[, chunksize])`
  - onde *kind* pode ser *STATIC*, *DYNAMIC*, *GUIDED* ou *RUNTIME*
  - e *chunksize* é uma expressão inteira com valor positivo, a qual divide o espaço de iterações em pedaços, cada um com *chunksize* iterações
    - os pedaços são atribuídos ciclicamente a cada *thread* (escalonamento *block cyclic*)
- Ex.: `#pragma for schedule(DYNAMIC, 4)`

# Escalonamento *SCHEDULE* *STATIC*



# Escalonamento DYNAMIC

- Divisão do espaço de iteração em pedaços de tamanho *chunksize*
  - Atribuição para as *threads* com uma política *firstcome-first-served*
  - i.e. se uma *thread* terminou um pedaço, ela recebe o próximo pedaço na lista
- Quando nenhum valor de *chunksize* é especificado, o valor padrão é 1

# Escalonamento *GUIDED*

- Similar ao *DYNAMIC*, mas os pedaços iniciam grandes e se tornam pequenos exponencialmente
  - O tamanho do próximo pedaço é (a grosso modo) o número de iterações restantes dividido pelo número de *threads*
  - O valor *chunksize* especifica o tamanho mínimo dos pedaços
- Quando nenhum valor de *chunksize* é especificado, o padrão é 1



# Escalonamentos

## *DYNAMIC* e *GUIDED*

